Aplicaciones de inteligencia artificial a la restauración e interpretación de textos antiguos

Hacia un marco de metadatos y preservación digital de sus resultados
Proyecto de trabajo de fin de máster

Patricio Iván Pantaleo
Máster Universitario en Bibliotecas, Archivos y Continuidad Digital
Universidad Carlos III de Madrid
Director: Ricardo Eito Brun

15 de octubre de 2026

Índice

1. Problema **2**

2. Pregunta de investigación **3**

3. Objetivos **3**

4. Marco teórico **3**
4.1 La IA aplicada a textos antiguos 4
4.2 La proveniencia de lo generado por máquinas 4
4.3 La preservación digital como eje normativo 4
4.4 Punto de cruce: la salida como objeto a preservar 5

5. Metodología **6**
5.1 Criterios de inclusión 6
5.2 Ventana temporal 6
5.3 Jerarquía de fuentes de evidencia 6
5.4 Rejilla de análisis: dos capas 7
5.5 Fuentes y estrategia de búsqueda 7
5.6 Cribado por título y resumen 8
5.7 Unidad de análisis: el proyecto 9
5.8 Formulario de *charting* 10

6. Corpus semilla **11**

7. Objeto de estudio **12**
7.1 Definición operativa de "texto antiguo" (D13) 12

8. Declaración de uso de inteligencia artificial **13**

9. Repositorio de materiales **14**

10. Plan de la memoria **14**

1. Problema

Los sistemas de inteligencia artificial aplicados a textos antiguos producen aserciones sobre objetos del patrimonio documental: restauran lagunas, atribuyen origen geográfico, datan, transcriben, leen soportes físicamente inaccesibles. Esas aserciones mayoritariamente son probabilísticas —el modelo no devuelve *un* resultado sino una distribución sobre resultados posibles— y son revisadas, corregidas o adoptadas por especialistas humanos.

El resultado de ese proceso es un activo digital que circula: se cita, se reutiliza, se incorpora a ediciones y a bases de datos. Pero se desconoce en qué medida ese activo viaja acompañado de la documentación que permitiría, más adelante, saber qué lo produjo, con qué versión de qué modelo, con cuánta certeza, y quién lo validó.

Ese desconocimiento —y no su respuesta presupuesta— es el punto de partida.

2. Pregunta de investigación

RQ. ¿Qué metadatos de proveniencia y preservación se registran actualmente en las aplicaciones de inteligencia artificial a la restauración e interpretación de textos antiguos?

Subpreguntas:

- **SQ1.** ¿Qué registra efectivamente cada proyecto, sin categorías previas?
- **SQ2.** ¿Cómo se mapea lo registrado sobre PREMIS, METS e ISO 23081?
- **SQ3.** ¿Qué exigen esos estándares que los proyectos no tengan, y qué tienen los proyectos que esos estándares no puedan alojar?
- **SQ4** (*condicional al hallazgo*). Si se confirma una carencia, ¿qué extensión mínima la cubriría?

Naturaleza del diseño. Es un estudio diagnóstico. Si los proyectos documentan, se releva y se contrasta; si no documentan, se releva igual y además se esboza una propuesta. La consecuencia metodológica es que **la defensa del trabajo no descansa en el resultado sino en el protocolo**: sus puntos vulnerables son la cadena de búsqueda, los criterios de inclusión y la rejilla de análisis, no las conclusiones.

3. Objetivos

General. Relevar qué metadatos de proveniencia y preservación se registran en las aplicaciones de IA a textos antiguos, y contrastar lo relevado con los estándares archivísticos de preservación digital.

Específicos.

1. Construir, mediante protocolo reproducible, el corpus de proyectos que cumplen los criterios de inclusión.
2. Caracterizar inductivamente qué metadatos genera, usa y persiste cada proyecto, distinguiendo los de entrada y entrenamiento de los de salida.
3. Mapear lo relevado sobre PREMIS, METS e ISO 23081, y analizar el desajuste en ambas direcciones.
4. (*Condicional*) Si el relevamiento confirma carencias, esbozar una extensión de metadatos que las cubra, en anexo o corolario, validada conceptualmente sobre uno o dos casos.

4. Marco teórico

El objetivo general excede el alcance de un solo estándar. Pone en relación tres cuerpos de literatura que hoy apenas se citan entre sí: el campo que aplica inteligencia artificial a textos antiguos, el problema general de la proveniencia de lo generado por máquinas y la normativa de preservación digital. El marco se organiza en esos tres ejes y en su punto de cruce, que es donde se sitúa la pregunta.

4.1 La IA aplicada a textos antiguos

El campo tiene ya un mapa propio: el *survey* de Sommerschield et al. (2023) ordena las tareas —restauración de lagunas, atribución geográfica y temporal, transcripción y HTR, traducción automática, desciframiento, búsqueda y alineamiento de paralelos— y fija la delimitación del objeto que este trabajo adopta en §7.1.

Lo que ese campo documenta de sí mismo está bien establecido: arquitectura del modelo, composición del corpus de entrenamiento, procedimiento de evaluación y métricas de rendimiento (exactitud *top-k*, tasa de error por carácter, *perplexity*). Esa documentación responde a la pregunta de la comunidad de aprendizaje automático —si el modelo funciona y es comparable con otros— y no a la de la comunidad archivística —qué es, de dónde viene y qué garantías tiene cada resultado concreto que el modelo produjo—. La distancia entre ambas preguntas es el espacio del trabajo.

El rasgo que vuelve el problema específico es el estatuto de la salida. Un modelo de restauración no devuelve una lectura sino un conjunto ordenado de lecturas posibles con sus probabilidades. Lo que se publica después suele ser una de ellas, elegida por un especialista: la aserción que circula es el producto conjunto de un modelo y de un juicio humano, y ninguno de los dos queda necesariamente inscrito en ella.

4.2 La proveniencia de lo generado por máquinas

Fuera del patrimonio documental el problema tiene instrumentos en circulación, que se reseñan como estado del arte y no como base del marco:

- Las **fichas de modelo** y las **hojas de datos** (*model cards*, *datasheets for datasets*) documentan el modelo y el conjunto de entrenamiento, no cada salida producida con ellos.
- **PROV-O** (W3C) modela de forma genérica entidad, actividad y agente; es el vocabulario de procedencia más extendido en la web de datos, pero no define obligaciones de preservación ni se integra en los paquetes de información de los repositorios.
- **C2PA** adhiere credenciales de contenido al archivo e identifica intervención algorítmica; está pensado para fotografía y medios, con infraestructura de firma propia.
- **CIDOC-CRM** y su extensión **CRMdig** modelan el proceso de digitalización y la cadena de derivación en el ámbito museístico.
- El proyecto europeo **ECCCH / EDEN-FIDELIS** se cita como evidencia de que el problema está en la agenda institucional (referencia pendiente de verificación).

Ninguno de estos instrumentos pertenece al contenido curricular del máster ni es el vehículo habitual de la preservación en archivos y bibliotecas. Su función en el trabajo es doble: situar el problema en un debate más amplio y comprobar si alguna pieza ya resuelta en ellos puede reutilizarse antes de proponer nada nuevo.

4.3 La preservación digital como eje normativo

Estándar	Qué aporta al análisis
PREMIS	Modela `Object`, `Event`, `Agent` y `Rights`. Contempla que un *software* sea agente, con versión, ejecutando un evento fechado con un resultado sobre un objeto. Es el molde más directo para "qué modelo produjo esta salida"
METS	Empaquetado y estructura. Pregunta algo que PREMIS no: si existe siquiera un objeto digital con envoltorio, o si el resultado circula como dato suelto sin metadatos adheridos
ISO 23081	Modelo entidad-relación (documentos, agentes, actividades, reglas). Puente conceptual con el contenido ya cursado; da la estructura de nivel superior de la rejilla

La elección no es neutral y conviene declararla: estos tres estándares son los que efectivamente gobiernan la conservación a largo plazo en las instituciones de memoria, que son el destinatario del trabajo. Que una salida de IA sea preservable significa, en términos prácticos, que una institución pueda ingestarla, describirla y conservarla con los instrumentos que ya usa.

4.4 Punto de cruce: la salida como objeto a preservar

Los tres ejes se cruzan en una pregunta que ninguno responde solo: qué hace falta que acompañe a una lectura restaurada por un modelo para que, dentro de veinte años, siga siendo interpretable como lo que es —una propuesta con un grado de certeza, producida por un sistema concreto y aceptada por alguien—, y no un dato más dentro de una edición.

Tres tensiones conceptuales organizan ese cruce y guían la capa normativa de la rejilla (§5.4):

1. **Determinismo frente a distribución.** PREMIS fue diseñado para eventos deterministas: una migración de formato se completa o falla. Un modelo emite un resultado probabilístico, y las alternativas descartadas también son información. No se ha identificado en PREMIS una unidad semántica que aloje el grado de confianza sin recurrir a texto libre en `eventOutcomeDetailNote`. **Antes de afirmar la carencia hay que verificar si ya existe una extensión propuesta** (V2 del protocolo de trabajo).
2. **Entidad intelectual frente a objeto.** PREMIS distingue la entidad intelectual del objeto digital que la representa. Una restauración obliga a decidir si la salida es una representación nueva del testimonio o una aserción sobre él; la respuesta cambia dónde se ancla la proveniencia.
3. **Evento de preservación frente a evento de interpretación.** El vocabulario de eventos de PREMIS está poblado de operaciones técnicas. Una inferencia que propone texto no es una operación técnica sobre el objeto, sino un acto interpretativo que produce conocimiento nuevo. Si entra en el mismo vocabulario, hay que justificarlo; si no entra, el desajuste es un hallazgo.

Estas tensiones son hipótesis de trabajo, no premisas: el relevamiento puede confirmarlas, matizarlas o refutarlas.

5. Metodología

Diseño: scoping review conforme a PRISMA-ScR, con análisis de artefacto embebido sobre el subconjunto inspeccionable.

No es una revisión sistemática: no responde una pregunta de efectividad ni practica valoración de calidad de evidencia. Es un mapeo de la extensión, el rango y la naturaleza de una práctica. Su paso de *data charting* produce la matriz comparativa, que es a la vez instrumento y producto.

5.1 Criterios de inclusión

Un proyecto entra si cumple **todas** estas condiciones (en §5.6 se operacionalizan como C1–C4):

1. Existe un proceso de IA en la lectura o interpretación del material — incluido el análisis de **materialidad** del soporte, no solo del contenido.
2. Existe un producto digital resultante de esa acción sobre el cual evaluar metadatos. No es necesario que sea una imagen: puede ser texto, dato estructurado o modelo.
3. El material son **textos antiguos** según la definición de §7.1.
4. Si el corpus mezcla épocas, trabaja **principalmente** con textos anteriores al corte (§7.1).

Exclusiones que estos criterios producen: el Khipu Database Project de Urton y el Proyecto Digital de Manuscritos del Mar Muerto (digitalización y catalogación sin IA).

Lengua y escritura no son criterio de selección. Entra una aplicación a cualquier lengua o sistema de escritura antiguo (griego, latín, hebreo, acadio, chino clásico, tamil, maya, etc.) si cumple las condiciones anteriores. Lo que se evalúa es la aplicación de IA, no la tradición textual. La lengua y la escritura se registran como variables descriptivas (§5.4).

5.2 Ventana temporal

Corte: 2022, con capítulo de antecedentes.

Fundamento: el corte no marca la aparición de la IA aplicada a textos antiguos —que es anterior— sino el momento en que el problema de proveniencia se vuelve efectivo. Pythia (2019) restauraba y nada más; Ithaca (2022) restaura, atribuye geográficamente y data, con interfaz pública. Es el punto en que estos sistemas pasan a emitir múltiples clases de aserción, cada una con su incertidumbre, y a circular fuera del laboratorio.

Regla complementaria: los proyectos activos de larga data entran por sus publicaciones desde 2022, sin que su fecha de inicio los excluya. Así el DRI —fundacional en 2016— permanece en el corpus.

5.3 Jerarquía de fuentes de evidencia

De mayor a menor peso probatorio:

1. **Salida del modelo tal como circula** (interfaz pública o resultado incorporado en publicaciones y bases; evidencia primaria)
2. Documentación del software y repositorio
3. Material suplementario

4. Artículo científico (declaración de los autores)

Objeto de evaluación: la salida que circula y se cita, no la que puede reproducirse en local. El nivel 1 corresponde a la salida tal como la entrega la interfaz pública del proyecto (p. ej., predictingthepast.com para Ithaca y Aeneas) o tal como aparece incorporada en publicaciones y bases de datos. La ejecución local y la lectura del código quedan como evidencia de contraste (nivel 2).

> **Advertencia de interpretación.** Que un proyecto no sea auditable públicamente no prueba que no documente. La afirmación defendible es "no es verificable públicamente que documente", no "no documenta". Esa opacidad es en sí misma un hallazgo, y se lee en clave de prácticas FAIR.

5.4 Rejilla de análisis: dos capas

Capa	Qué hace	Por qué
A — Inductiva	Registra qué documenta cada proyecto sin categorías previas	Una rejilla derivada solo de PREMIS sería ciega a lo que los proyectos sí registran —corpus de entrenamiento, arquitectura, hiperparámetros, procedencia del material— que PREMIS no contempla
B — Normativa	Ubica lo relevado en PREMIS / METS / ISO 23081	Deriva las categorías del estándar y no de la intuición del autor

El análisis del vacío se lee **en las dos direcciones**: lo que el estándar exige y no está, y lo que está y el estándar no puede alojar. La segunda dirección es la más original: no dice que los proyectos estén mal, dice que el instrumento no fue diseñado para esto.

Variables descriptivas del *data charting* (caracterizan cada caso; no sirven para seleccionar):

- Lengua y sistema de escritura
- Soporte (piedra, bronce, arcilla, papiro, pergamino, bambú, hoja de palma…)

La unidad sobre la que se aplica la rejilla se define en §5.7 y el formulario completo de preguntas, en §5.8.

5.5 Fuentes y estrategia de búsqueda

Fuente	Función	Justificación
OpenAlex	Base principal	Cobertura amplia y abierta, que incluye preprints (arXiv) y actas de ACL. Admite búsqueda booleana en título y resumen con filtro temporal. La consulta por API es reproducible y deja registro automático.

Fuente	Función	Justificación
Scopus (acceso institucional UC3M)	Base complementaria	Cubre el punto débil de OpenAlex: en el piloto, el 16 % de los registros no tenía resumen, sobre todo de editoriales como Elsevier. Busca también en palabras clave de autor e indexadas (`TITLE-ABS-KEY`).
Snowballing	Complemento	Hacia atrás (referencias) y hacia adelante (citas) desde el seed set y los estudios incluidos, con `referenced_works` y `cited_by` de OpenAlex. Recupera casos que la cadena no capta, sea por falta de términos generales de IA (Lacuna) o por términos quitados para reducir ruido (D16). Los registros encontrados así se cuentan aparte en el diagrama PRISMA ("otros métodos").

Cadena. Dos bloques unidos por AND: (1) términos generales de IA y (2) términos de textos antiguos, soportes y escrituras. **No se incluyen nombres de técnicas o arquitecturas** (CNN, RNN, transformer…), porque suben la cobertura a costa de mucho ruido (decisión D11). Cada versión de la cadena se guarda en `busqueda/consultas/` y no se sobrescribe. La sintaxis de OpenAlex y la de Scopus no son idénticas; su equivalencia se documenta en el registro de cada corrida.

Registro para PRISMA-ScR. Para cada fuente: fecha de ejecución, cadena literal, registros recuperados, duplicados eliminados (por DOI y, si falta, por título normalizado) y registros que pasan al cribado. OpenAlex se consulta con `busqueda/buscar_openalex.py`. Scopus se consulta a mano en *Advanced document search*, se exporta en CSV con resumen y se fusiona con OpenAlex por DOI. **Crossref** no es fuente de búsqueda —no admite operadores booleanos— y se usa solo como servicio de metadatos: completa los registros y genera el BibTeX a partir del DOI.

5.6 Cribado por título y resumen

Hoja de criterios. Cada registro se evalúa con cuatro preguntas derivadas de §5.1, §7.1 y D14:

#	Pregunta	Si la respuesta es "no"
C1	¿Hay un proceso de IA (aprendizaje automático, redes neuronales, visión por computador, modelos de lenguaje) aplicado a la lectura o interpretación del material, incluida su materialidad?	Excluir, E1

#	Pregunta	Si la respuesta es "no"
C2	¿Hay un producto digital resultante (texto restaurado, transcripción, atribución, modelo, dataset, imagen procesada…)?	Excluir, E2
C3	¿El material son textos antiguos según §7.1 (obra compuesta antes de finales del primer milenio d. C., en cualquier lengua, escritura o soporte)?	Excluir, E3
C4	Si el corpus mezcla épocas, ¿trabaja principalmente con textos anteriores al corte?	Excluir, E4

Códigos de exclusión adicionales:

- **E5:** tipo documental sin estudio primario (editorial, fe de erratas, retractación, presentación de volumen de actas, índice).
- **E6:** tema ajeno, cuando el registro entró por coincidencia léxica.
- **R:** revisión o *survey* pertinente. No entra en el corpus, pero se usa como fuente de *snowballing*.

Regla de duda. En esta fase, ante información insuficiente se marca **dudoso** y el registro pasa a lectura de texto completo. Solo se excluye cuando el título y el resumen permiten afirmarlo.

Cribado asistido por IA (declaración de uso). Claude (Anthropic, modelo Opus 5) propone para cada registro una decisión (incluir, excluir, dudoso o R), un código y un motivo breve, siguiendo las instrucciones de `busqueda/cribado/instrucciones-cribado-ia.md`. La propuesta se guarda sin modificar (`busqueda/cribado/propuesta-ia-v1.csv`). **El autor revisa todas las inclusiones, los dudosos y los R, y una muestra aleatoria de las exclusiones para estimar el acuerdo.** Solo las decisiones revisadas pasan a `busqueda/cribado/decisiones.csv`.

Fuera de esta búsqueda: la literatura archivística sobre PREMIS y proveniencia (V2) no forma parte del corpus de proyectos y necesita su propia búsqueda dirigida.

5.7 Unidad de análisis: el proyecto

El trabajo usa dos unidades distintas y no intercambiables:

- **Unidad de recuperación y cribado: la referencia bibliográfica.** Es la que cuenta el diagrama PRISMA-ScR, porque lo que se busca, se deduplica y se criba son publicaciones.
- **Unidad de análisis y de *charting*: el proyecto.** Es la que ocupa una fila de la matriz comparativa, porque los metadatos de proveniencia no los documenta un artículo, los documenta —o no— el sistema que produce las salidas.

Esta distinción es necesaria: un mismo proyecto puede tener cuatro publicaciones y una sola política de documentación, y contarlo cuatro veces sobrerrepresentaría a los equipos que más publican, que son también los que más recursos tienen. Contar proyectos, y no artículos, es lo que hace que la matriz describa prácticas y no volumen editorial.

Definición. Un **proyecto** es un sistema o aplicación identificable que produce salidas sobre un corpus de textos antiguos. Se considera una sola unidad cuando coinciden los cuatro rasgos siguientes:

1. un modelo o sistema identificable (nombre propio, repositorio de código o interfaz pública);
2. un equipo o institución responsable con continuidad;
3. una tarea y un corpus sustancialmente estables;
4. una salida que circula bajo una identidad reconocible.

Reglas de agrupación y separación.

- Varias publicaciones del mismo sistema —artículo original, versión ampliada, evaluación posterior, descripción del conjunto de datos— forman **una** unidad. Las publicaciones posteriores aportan datos a la misma fila.
- Un **modelo nuevo con salida propia** es unidad propia aunque lo firme el mismo equipo y herede del anterior. Pythia, Ithaca y Aeneas son tres unidades, no una. Se registra el linaje en un campo de la matriz, de modo que la familia siga siendo visible.
- Un ajuste de hiperparámetros, una reimplementación, una traducción a otro marco de trabajo o una evaluación añadida **no** crean unidad.
- Dos sistemas con el mismo nombre y equipos distintos son dos unidades.

Estudios sin sistema identificable. Buena parte de la literatura recuperada son experimentos puntuales, sin nombre propio, sin código publicado y sin interfaz. Excluirlos sesgaría el relevamiento hacia los proyectos de alta visibilidad, que es justamente la práctica que se quiere describir sin idealizar. Entran como unidad, con la publicación como identificador, y la matriz distingue el tipo de unidad en un campo explícito:

Tipo de unidad	Qué es	Qué se espera del *charting*
Sistema	Tiene nombre, interfaz o repositorio; la salida circula de forma identificable	Se puede evaluar hasta el nivel 1 de evidencia (§5.3)
Estudio	Experimento publicado sin sistema identificable ni salida circulante	El análisis suele detenerse en los niveles 2 a 4; la ausencia de salida auditable se registra como dato, no como carencia del estudio

Trazabilidad del paso de una unidad a otra. La correspondencia entre referencias y proyectos se publica como tabla (`busqueda/proyectos.csv`), con una fila por referencia incluida y la clave del proyecto al que se asigna. El informe final declara ambas cifras: estudios incluidos tras la lectura de texto completo y proyectos resultantes. La agrupación es una decisión del autor, no un cálculo: por eso se publica, para que sea discutible.

5.8 Formulario de *charting*

La rejilla de §5.4 se operacionaliza como una guía de preguntas aplicada a cada proyecto. **Cada celda registra, además del hallazgo, el nivel de evidencia con que se obtuvo** (§5.3), de modo que la asimetría entre proyectos auditables y opacos quede visible en los datos.

Bloque	Preguntas	Parámetros registrados
1. Identificación	¿Qué sistema es, quién lo sostiene, desde cuándo?	Nombre, equipo, institución, años de actividad, referencias asociadas, tipo de unidad, linaje
2. Material de entrada	¿Sobre qué trabaja y de dónde viene?	Lengua, escritura, soporte, época del texto, corpus de origen, licencia, identificador de los testimonios procesados
3. Proceso	¿Qué hace y con qué?	Tarea (restauración, atribución, datación, transcripción, traducción…), familia de modelo, versión, datos de entrenamiento, dependencia de servicios externos
4. Salida	¿Qué produce y dónde circula?	Forma del resultado, canal (interfaz, repositorio, publicación, base de datos), formato, licencia, identificador persistente
5. Enlace entrada–salida	¿La salida permite volver al testimonio del que procede?	Presencia de identificador del material de origen en la salida; granularidad del enlace
6. Incertidumbre	¿Se expresa el grado de certeza y las alternativas?	Forma (probabilidad, *top-k*, intervalo, ninguna), persistencia de las alternativas descartadas
7. Intervención humana	¿Consta que alguien revisó y aceptó el resultado?	Existencia de revisión, identificación del revisor, fecha, efecto sobre la salida
8. Identidad del productor	¿La salida dice qué la produjo?	Versión del modelo, fecha de la inferencia, versión del software, parámetros
9. Empaquetado y preservación	¿Hay un objeto digital con metadatos adheridos y un plan?	Esquema declarado, repositorio de depósito, política de preservación, versionado
10. Capa normativa	¿Dónde se aloja cada hallazgo en PREMIS, METS e ISO 23081, y qué no tiene alojamiento?	Entidad y elemento del estándar, o anotación de desajuste en una u otra dirección

Los bloques 1 a 9 forman la capa inductiva y el bloque 10, la normativa. Los bloques 5 a 8 concentran el núcleo de la pregunta de investigación: son los que distinguen una salida que puede preservarse con sentido de una que solo puede archivarse como cadena de texto.

El formulario se aplica primero a dos proyectos de prueba —uno con interfaz pública y otro sin ella— y se ajusta antes de aplicarlo al resto. Esa versión de prueba y la definitiva se conservan ambas en el repositorio de materiales (§9).

6. Corpus semilla

Los proyectos del documento inicial **no son la muestra**: son el conjunto semilla con el que se valida la estrategia de búsqueda. El corpus final lo determina el protocolo, y puede resultar mayor o menor.

Seed set operativo (10 trabajos con publicación desde 2022, en `busqueda/consultas/v1.json`): Ithaca, Aeneas, Enoch, BiNet, DR-LIFT, lineal B (Papavassileiou et al.), acadio NMT (Gutherz et al.), Lacuna, glifos mayas (Pinilla-Buitrago et al.) y el *survey* de Sommerschield et al.

Regla de validación. El seed set valida la **estrategia completa** (bases de datos más *snowballing*), no solo la cadena. Se informan por separado los trabajos recuperados por la cadena en cada base y los que se recuperan por *snowballing*. Un trabajo semilla que no aparezca por ninguna vía indica un fallo de la estrategia. Resultado de la cadena v1: 8/10 (faltan Lacuna y Pinilla-Buitrago, que deben aparecer por *snowballing*; ver V8).

7. Objeto de estudio

"Textos antiguos", no "manuscritos". Es el término que cubre a la vez la inscripción epigráfica (Ithaca, Aeneas: piedra y bronce; DR-LIFT: inscripciones tamiles en piedra), el rollo y el papiro (DRI, Enoch), la tablilla (acadio, lineal B) y el manuscrito (Lacuna). Las particularidades de cada soporte se detallan dentro del trabajo.

7.1 Definición operativa de "texto antiguo" (D13)

Se adopta la delimitación de Sommerschield et al. (2023, p. 705), por ser la referencia de autoridad del campo:

> "ancient texts written in ancient languages [...] all languages in use across the world, written on any medium and in any script, between the birth of writing systems in ancient Mesopotamia (3400 BCE) up until the conventional end of 'ancient history' in the late first millennium CE."

Qué se fecha: el texto (la obra), no el soporte conservado. Consecuencias para el cribado:

- **Entran** las copias posteriores de obras antiguas. Por ejemplo, una aplicación sobre manuscritos medievales de la *Ilíada*.
- **No entran** las obras compuestas después del corte, aunque retomen textos antiguos (adaptaciones, paráfrasis) o usen una lengua de origen antiguo que siguió escribiéndose (latín medieval, chino literario tardío).
- La lengua y la escritura siguen sin ser criterio (D12). El criterio es la época del texto.

Corpus mixtos (modelos entrenados con textos anteriores y posteriores al corte): entran **solo si trabajan principalmente con textos anteriores al corte**. Criterio provisional (D14), a revisar con los casos reales del cribado.

Quipu: queda fuera del TFM (D15). Sus registros conservados son incaicos (siglos XV–XVI). Solo se conserva esta nota por si se retoma en el doctorado.

8. Declaración de uso de inteligencia artificial

El trabajo usa un asistente de IA (Claude, de Anthropic, modelo Opus 5, a través de Claude Code) como herramienta instrumental. Se declara aquí el alcance exacto de ese uso, por coherencia con el objeto del propio trabajo —la proveniencia de lo producido con ayuda de máquinas— y con la Guía de buenas prácticas de la Universidad Carlos III de Madrid (2012, apartado 2.H).

En qué se usa.

Tarea	Uso	Rastro que queda
Consulta de APIs	Construcción y ejecución de las consultas a OpenAlex y de la recuperación de metadatos por DOI en Crossref	Scripts y registro de cada corrida
Programación	Escritura de los *scripts* de búsqueda, fusión, deduplicación y preparación del cribado, en Python	Código completo en el repositorio público (§9)
Cribado por título y resumen	Propuesta de decisión, código y motivo para cada registro, según una hoja de instrucciones fija	Instrucciones literales, propuesta sin modificar y revisión del autor
Verificación	Detección de inconsistencias internas del protocolo y de los criterios aplicados	Registro de decisiones y de enmiendas
Redacción	Formulación y pulido de secciones a partir de decisiones tomadas por el autor en diálogo	El autor revisa, corrige y asume cada párrafo

En qué no se usa. No se delegan las decisiones metodológicas, la definición del objeto y de los criterios, la lectura de los textos completos, la cumplimentación del formulario de *charting*, la interpretación de los resultados ni las conclusiones. La IA no es fuente: nada se afirma en el trabajo porque un modelo lo haya dicho, y las referencias se verifican una a una contra Crossref o contra la publicación.

Condición del cribado asistido. La propuesta de la IA no es una decisión. Es una capa previa, equivalente a la de un segundo cribador, sobre la que el autor decide: revisa todas las inclusiones, los dudosos y los *surveys*, y una muestra aleatoria estratificada de las exclusiones, con la que se estima el acuerdo. La cifra de acuerdo se informa en la memoria. Las propuestas sin revisar no entran en el corpus.

Trazabilidad. Las instrucciones que recibió el modelo, su propuesta sin modificar y las decisiones del autor se conservan por separado y se publican en el repositorio (§9). El criterio es el mismo que el trabajo exige a los proyectos que estudia: que la salida de un modelo viaje acompañada de qué la produjo, con qué instrucciones y quién la validó.

9. Repositorio de materiales

Los materiales que permiten auditar y reproducir el relevamiento se publican en un repositorio de código abierto, al que la memoria remite desde la metodología. Contiene:

- los *scripts* de búsqueda en OpenAlex, de fusión con la exportación de Scopus y de deduplicación;
- las cadenas de búsqueda de cada versión, en su formato literal para cada fuente;
- el registro de cada corrida, con fecha, cifras y cómputo de duplicados;
- las instrucciones del cribado asistido y la propuesta de la IA sin modificar;
- las decisiones del autor y la tabla de correspondencia entre referencias y proyectos (§5.7);
- el formulario de *charting* y la matriz resultante.

El código se publica bajo licencia MIT y los datos y documentos propios bajo CC BY 4.0. **Se publican también los datos en bruto de las dos fuentes**: la respuesta de la API de OpenAlex y la exportación manual de Scopus. Sin ellos, la auditoría del relevamiento se detiene en la palabra del autor. La exportación de Scopus procede de una base de suscripción cuyas condiciones de uso no contemplan la redistribución: se publica como material de auditoría, en la cantidad mínima necesaria, y se sustituirá por la lista de identificadores si el titular lo requiere.

Se publica solo la corrida en vigor. El piloto que sirvió para calibrar la cadena no sostiene ningún resultado y queda en la carpeta de trabajo.

La memoria no incluye como anexo impreso lo que el repositorio ya contiene: los anexos del documento se limitan a la matriz comparativa y al diagrama PRISMA-ScR, y el resto se cita por referencia al repositorio.

10. Plan de la memoria

Estructura. La exigida por la memoria de verificación del máster para el TFM: diseño de la investigación (objeto, objetivos, hipótesis, metodología, fuentes), resultados, discusión, conclusiones y referencias.

Extensión: 50 a 60 páginas, incluidas portada, índice y bibliografía. Los anexos pueden excederla; los materiales extensos van al repositorio (§9).

Parte	Páginas
Portada, índice, resúmenes (ES/EN)	4
1. Introducción y problema	5
2. Marco teórico	10
3. Metodología	8
4. Resultados del relevamiento	15
5. Discusión y análisis del desajuste	6
6. Conclusiones y líneas abiertas	3
Referencias	5
Total	**56**

Referencias: entre 50 y 60, conforme a la orientación del director. Reparto previsto: estándares

y normativa (8), campo de la IA aplicada a textos antiguos (25), proveniencia y documentación de modelos (8), metodología de revisión (5) y preservación digital y archivística (8).

> **Cómo se concilia ese límite con una revisión de alcance.** El corpus analizado puede superar las sesenta referencias. Para que no infle la bibliografía, **el corpus se presenta como tabla en anexo** —con autor, año, proyecto y DOI— y **en la lista de referencias solo entran los trabajos citados en el cuerpo del texto**. Es la práctica habitual en revisiones de alcance y mantiene legible la bibliografía sin ocultar el corpus.

Calendario. Pendiente de acordar con el director: fecha de entrega del proyecto, fecha de cierre del cribado y lectura de textos completos, fecha de entrega del borrador completo y convocatoria de defensa.